Analyse exploratoire et nettoyage de `name.basics`

Cette table va être utilisée pour les informations qu'elle apporte et non pour le machine learning.

**A l'issue de l'exploration et du nettoyage, 2 tables seront créées : 1 table `info_acteurs` et 1 table `info-films`

Introduction

Les étapes suivantes visent à analyser, nettoyer et préparer la table `name.basics` pour une utilisation ultérieure. Nous allons examiner chaque colonne, effectuer les transformations nécessaires et proposer des recommandations pour les prochaines étapes.

In [1]:
```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
import pandas as pd
```

Étape 1 : Chargement des données

In [26]:
```
# Importation du DataSet :
df_name_basics = pd.read_csv('../gitignore/name.basics.tsv', sep= '\t')
```

Aperçu rapide des données

In [27]:
```
df_name_basics.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 13958409 entries, 0 to 13958408
Data columns (total 6 columns):
 #   Column             Dtype 
---  ------             ----- 
 0   nconst             object
 1   primaryName        object
 2   birthYear          object
 3   deathYear          object
 4   primaryProfession  object
 5   knownForTitles     object
dtypes: object(6)
memory usage: 639.0+ MB
```

Étape 2 : Exploration et Nettoyage des données

Aperçu rapide des données

In [28]:
```
df_name_basics.head()
```

Out[28]:

	nconst	primaryName	birthYear	deathYear	primaryProfession	
0	nm0000001	Fred Astaire	1899	1987	actor,miscellaneous,producer	tt(
1	nm0000002	Lauren Bacall	1924	2014	actress,soundtrack,archive_footage	tt(
2	nm0000003	Brigitte Bardot	1934	\N	actress,music_department,producer	tt(
3	nm0000004	John Belushi	1949	1982	actor,writer,music_department	tt(
4	nm0000005	Ingmar Bergman	1918	2007	writer,director,actor	tt(

Identification des valeurs manquantes

In [29]:
```
df_name_basics.isna().sum()
```

Out[29]:
```
nconst               0
primaryName          9
birthYear            0
deathYear            0
primaryProfession    0
knownForTitles       0
dtype: int64
```

In [32]:
```
manquant_primary_name = df_name_basics[df_name_basics['primaryName'].isna()]

print("Lignes avec des valeurs manquantes dans `primaryName` :")
print(manquant_primary_name)

# Vérification du nombre total de valeurs manquantes
print(f"Nombre total de valeurs manquantes : {manquant_primary_name.shape[0]}")
```

```
Lignes avec des valeurs manquantes dans `primaryName` :
             nconst primaryName birthYear deathYear        primaryProfession  \
100967    nm0106021         NaN        \N        \N                    actor
1786541  nm10927938         NaN        \N        \N  art_department,composer
4927108  nm14292439         NaN        \N        \N                       \N
4962416  nm14334668         NaN        \N        \N                 director
4993716  nm14381073         NaN        \N        \N          director,writer
5877414  nm15383643         NaN        \N        \N                 composer
6311127  nm15901107         NaN        \N        \N                    actor
7029620  nm16712594         NaN        \N        \N           actor,composer
8387433   nm3177777         NaN        \N        \N                  actress

                  knownForTitles
100967                tt21610866
1786541  tt16401648,tt10837972
4927108                       \N
4962416                       \N
4993716  tt29359666,tt25049436
5877414               tt29568261
6311127               tt31613332
7029620               tt34519434
8387433                tt1315061
Nombre total de valeurs manquantes : 9
```

Remplacement des valeurs '\N' par NaN pour faciliter le traitement

In [33]:
```
df_name_basics = df_name_basics.replace(r'\\N', pd.NA, regex=True)
```

In [34]:
```
df_name_basics.head()
```

Out[34]:

	nconst	primaryName	birthYear	deathYear	primaryProfession	
0	nm0000001	Fred Astaire	1899	1987	actor,miscellaneous,producer	tt(
1	nm0000002	Lauren Bacall	1924	2014	actress,soundtrack,archive_footage	tt(
2	nm0000003	Brigitte Bardot	1934	<NA>	actress,music_department,producer	tt(
3	nm0000004	John Belushi	1949	1982	actor,writer,music_department	tt(
4	nm0000005	Ingmar Bergman	1918	2007	writer,director,actor	tt(

In [35]:
```
# Vérifier s'il existe des doublons dans la colonne 'nconst'
doublons = df_name_basics['nconst'].duplicated().sum()

if doublons > 0:
    print(f"Il y a {doublons} doublons dans la colonne 'nconst'.")
else:
    print("Toutes les valeurs de la colonne 'nconst' sont uniques.")
```

```
Toutes les valeurs de la colonne 'nconst' sont uniques.
```

Conversion des colonnes `birthYear` et `deathYear` en Date

In [36]:
```
# Convertir les colonnes birthYear et deathYear en format datetime tout en affic
df_name_basics['birthYear'] = pd.to_datetime(df_name_basics['birthYear'], errors
df_name_basics['deathYear'] = pd.to_datetime(df_name_basics['deathYear'], errors
df_name_basics['birthYear'] = df_name_basics['birthYear'].astype('Int64')
df_name_basics['deathYear'] = df_name_basics['deathYear'].astype('Int64')
```

Exportation de la base nettoyée pour name.basics_info_acteurs

- Exportation d'une table `info_acteurs_final` avec toutes les colonnes

In [37]:
```
df_name_basics.to_csv('../gitignore/name.basics_info_acteurs_final.tsv', sep= '\
```

- Exportation d'une table `info_films_final` avec toutes les colonnes

In [39]:
```
#drop des colonnes inutiles pour info_films
df_name_basics_info_film = df_name_basics[['nconst', 'primaryName']]
```

In [40]:
```
df_name_basics_info_film.head()
```

Out[40]:

	nconst	primaryName
0	nm0000001	Fred Astaire
1	nm0000002	Lauren Bacall
2	nm0000003	Brigitte Bardot
3	nm0000004	John Belushi
4	nm0000005	Ingmar Bergman

In [44]:
```
# export final
df_name_basics_info_film.to_csv('../gitignore/name.basics_info_film_final.tsv',
```

Étape 3 : Analyse Exploratoire, finalisation du nettoyage et recommandations

Explode de la colonne `primaryProfession`

- La colonne `primaryProfession` contient des valeurs `string array` qu'il va falloir exploder pour permettre une analyse et une utilisation ultérieure.

In [46]:
```
df_name_basics['primaryProfession'].value_counts()
```

Out[46]:
```
primaryProfession
actor                                                  2477780
actress                                                1590553
miscellaneous                                           809423
producer                                                479950
camera_department                                       432289
                                                         ...
stunts,producer,visual_effects                                1
set_decorator,location_management,make_up_department          1
make_up_department,miscellaneous,set_decorator                1
producer,stunts,archive_footage                               1
composer,director,archive_footage                             1
Name: count, Length: 23081, dtype: int64
```

In [47]:
```
# Conversion des professions en liste
df_name_basics['primaryProfession'] = df_name_basics['primaryProfession'].apply(
    lambda x: x.split(',') if isinstance(x, str) else []
)

# Explosion des professions
df_exploded_profession = df_name_basics.explode('primaryProfession', ignore_inde
```

In [14]:
```
df_exploded_profession.head()
```

Out[14]:

	nconst	primaryName	birthYear	deathYear	primaryProfession	
0	nm0000001	Fred Astaire	1899	1987	actor	tt0050419,tt00723
1	nm0000001	Fred Astaire	1899	1987	miscellaneous	tt0050419,tt00723
2	nm0000001	Fred Astaire	1899	1987	producer	tt0050419,tt00723
3	nm0000002	Lauren Bacall	1924	2014	actress	tt0037382,tt00752
4	nm0000002	Lauren Bacall	1924	2014	soundtrack	tt0037382,tt00752

In [48]:

```
df_exploded_profession['primaryProfession'].value_counts()
```

Out[48]:
```
primaryProfession
actor                         3231919
actress                       1953835
miscellaneous                 1452003
producer                      1240181
writer                         929001
camera_department              824771
director                       758973
art_department                 494564
sound_department               404326
cinematographer                403401
editor                         372346
composer                       351795
music_department               288759
assistant_director             269618
visual_effects                 250211
make_up_department             235403
animation_department           227679
production_manager             217547
archive_footage                202475
editorial_department           197164
costume_department             164343
soundtrack                     152187
transportation_department      107318
art_director                    97433
stunts                          92614
script_department               91696
location_management             87836
production_designer             84327
costume_designer                79136
special_effects                 69763
casting_department              59061
set_decorator                   58124
executive                       40427
casting_director                33114
manager                         14947
talent_agent                    14070
archive_sound                    5148
music_artist                     5052
legal                            4616
publicist                        4484
assistant                        3830
podcaster                         648
production_department             437
choreographer                     278
electrical_department              58
accountant                         49
Name: count, dtype: int64
```

In [49]:
```python
# Obtenir le comptage des professions
profession_counts = df_exploded_profession['primaryProfession'].value_counts()

# Création du graphique en barres
plt.figure(figsize=(10, 6))
profession_counts.plot(kind='bar', color='skyblue')

# Ajouter des titres et labels
plt.title('Distribution des professions', fontsize=16)
plt.xlabel('Professions', fontsize=12)
plt.ylabel('Nombre', fontsize=12)
```

```python
# Rotation des noms des professions pour une meilleure lisibilité
plt.xticks(rotation=45, ha='right', fontsize=10)

# Afficher le graphique
plt.tight_layout()
plt.show()
```

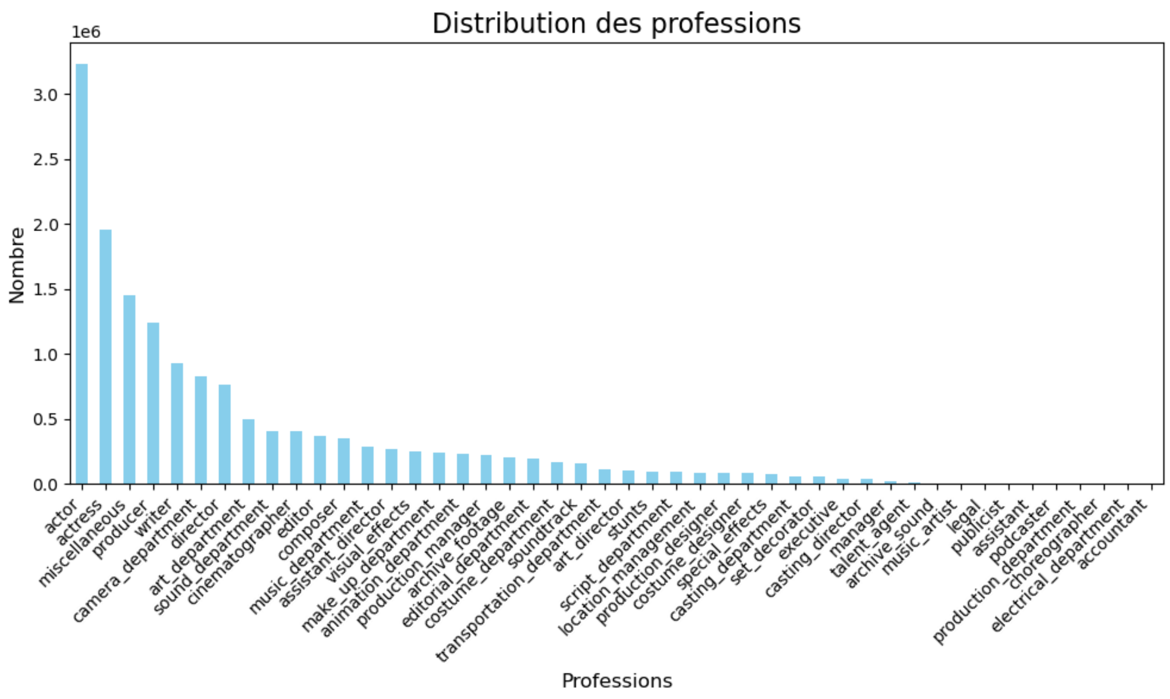

Arbitrage : Nous allons conserver les valeurs 'actor', 'actress', 'producer', 'writer', 'director' de la colonne 'primaryProfession'

In [50]:
```python
df_name_basics = df_exploded_profession.copy()

# Liste des professions à conserver
professions = ['actor', 'actress', 'producer', 'writer', 'director']

# Filtrer les lignes où la colonne 'primaryProfession' contient une valeur dans
df_name_basics = df_name_basics[df_name_basics['primaryProfession'].isin(profess
```

Analyse graphique

In [51]:
```python
df_name_basics['primaryProfession'].value_counts()
```

Out[51]:
```
primaryProfession
actor       3231919
actress     1953835
producer    1240181
writer       929001
director     758973
Name: count, dtype: int64
```

In [52]:
```python
# Proportions des professions (pie chart)
plt.figure(figsize=(8, 8))
profession_pie = df_name_basics['primaryProfession'].value_counts()
profession_pie.plot.pie(autopct='%1.1f%%', startangle=90, cmap='Set3')
plt.title("Répartition des professions")
plt.ylabel("")
plt.show()
```

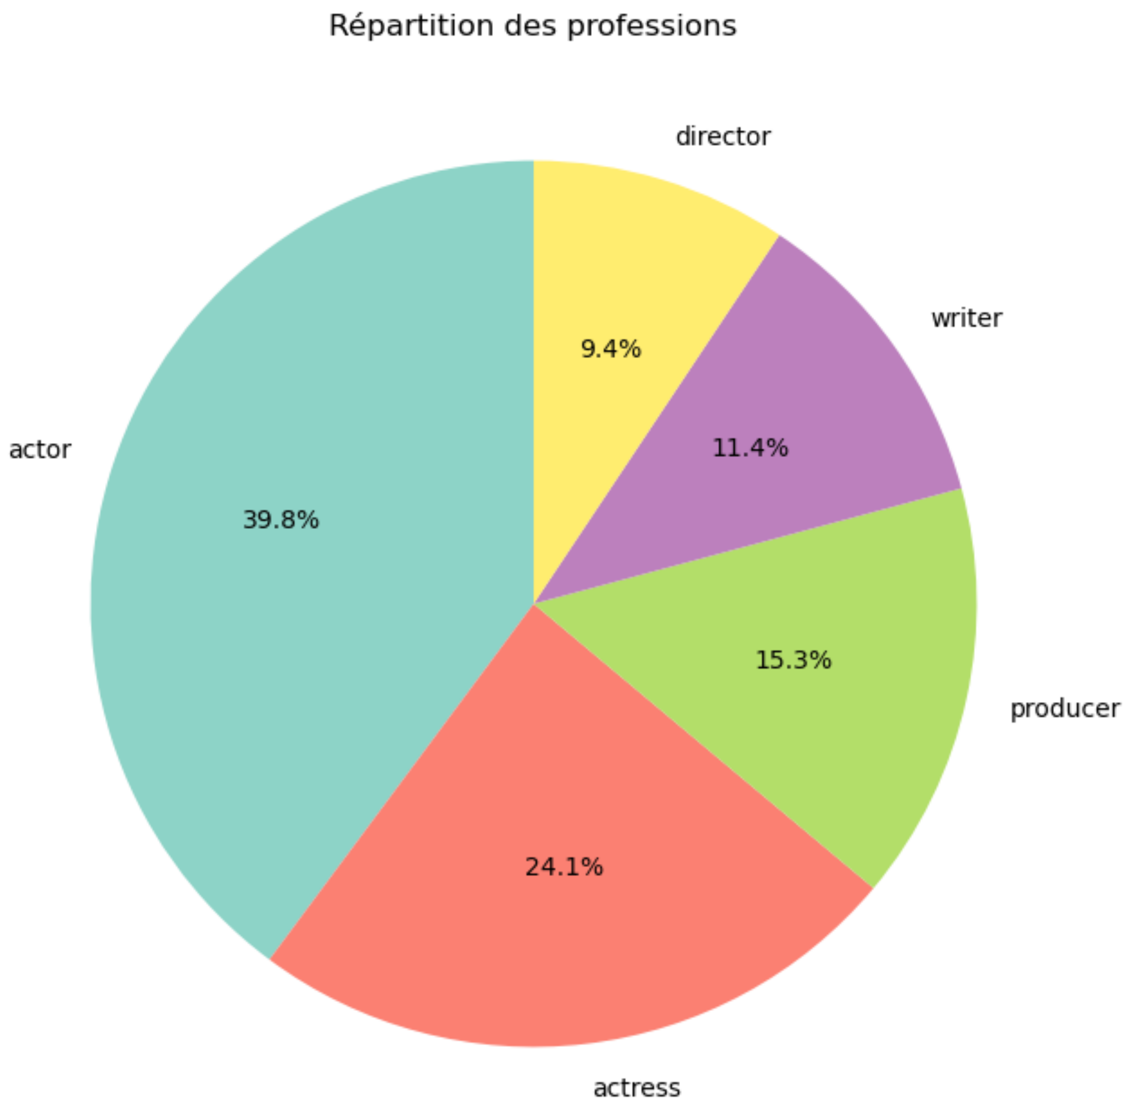

Fin de la 1ère exploration et du nettoyage

In [22]:
```
# 2. Analyse des noms les plus fréquents
plt.figure(figsize=(10, 6))
name_counts = df_name_basics['primaryName'].value_counts().head(10)
sns.barplot(x=name_counts.values, y=name_counts.index, hue = name_counts.index,
plt.title("Noms les plus fréquents")
plt.xlabel("Nombre d'occurrences")
plt.ylabel("Nom")
plt.show()
```

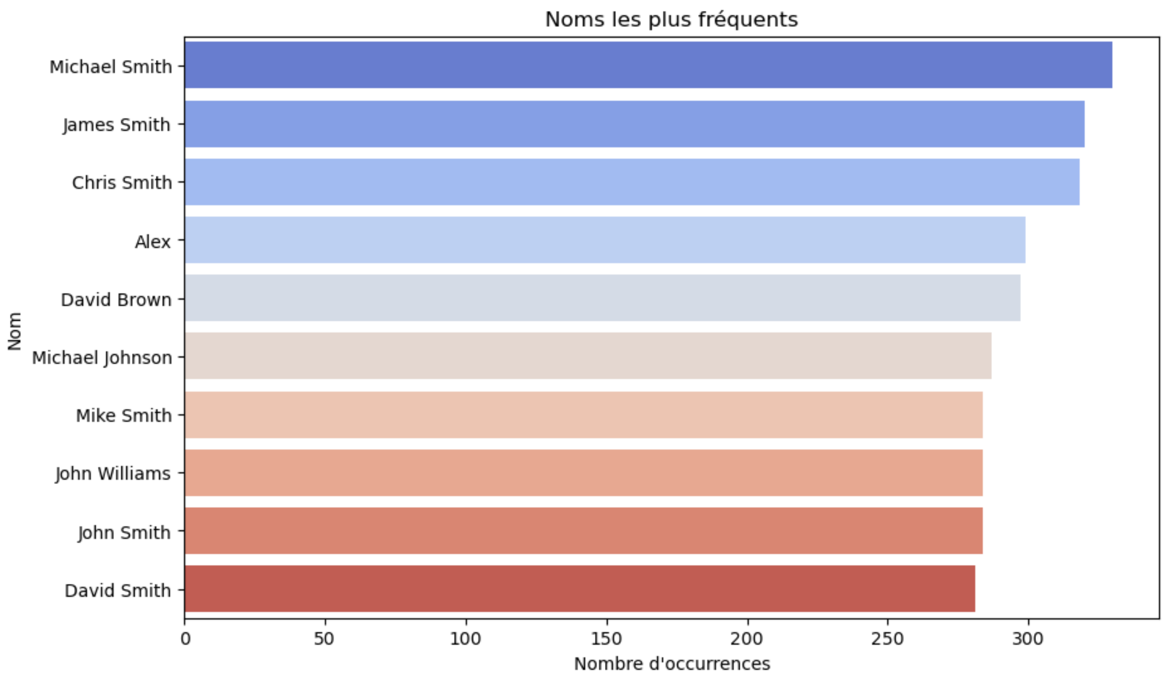

```
In [23]: # 3. Répartition des professions pour les noms les plus fréquents
         # Sélection des 10 noms les plus fréquents
         top_names = df_name_basics['primaryName'].value_counts().head(10).index
         top_names_df = df_name_basics[df_name_basics['primaryName'].isin(top_names)]

         # Création d'un graphique croisé
         plt.figure(figsize=(12, 8))
         sns.countplot(data=top_names_df, y='primaryName', hue='primaryProfession', palet
         plt.title("Répartition des professions pour les noms les plus fréquents")
         plt.xlabel("Nombre d'occurrences")
         plt.ylabel("Nom")
         plt.legend(title="Profession")
         plt.show()
```

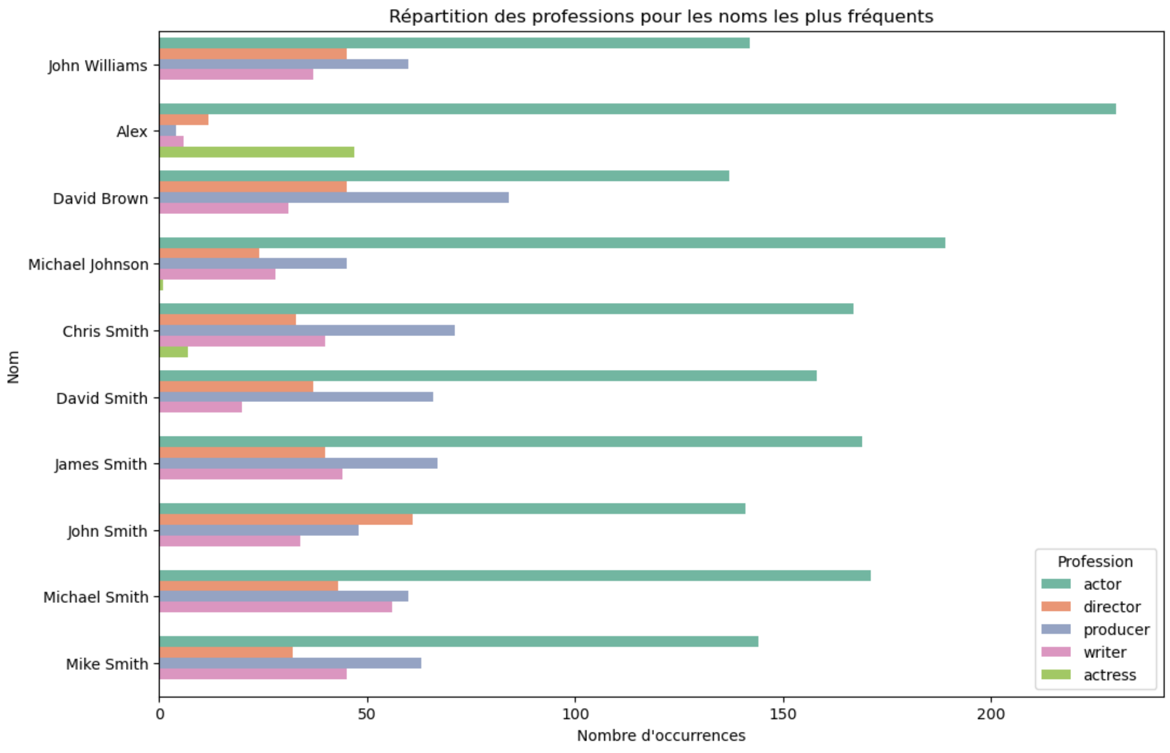
Répartition des professions pour les noms les plus fréquents
John Williams
Alex
David Brown
Michael Johnson
Chris Smith
David Smith
James Smith
John Smith
Michael Smith
Mike Smith
Nom
Profession
actor
director
producer
writer
actress
Nombre d'occurrences