Exploration du fichier source 'title.basics.tsv'

Étape 1 : Préparation et Importation des Données

```
In [1]: # 1. Importer les bibliothèques nécessaires
        import pandas as pd
        import numpy as np
        import matplotlib.pyplot as plt
        import seaborn as sns
In [3]: # 2. Charger le fichier TSV
        df_title_basics = pd.read_csv("../gitignore/title.basics.tsv",sep='\t')
       C:\Users\jpvt\AppData\Local\Temp\ipykernel_12424\830202319.py:3: DtypeWarning: Co
       lumns (4) have mixed types. Specify dtype option on import or set low_memory=Fals
         df_title_basics = pd.read_csv("../gitignore/title.basics.tsv",sep='\t')
In [4]: df_title_basics_copy = df_title_basics.copy()
In [5]: # 3. Aperçu initial des données :
        print(df_title_basics.info()) # Donne des informations sur les types de colonne
        print(df_title_basics.describe()) # Statistiques descriptives basiques (numériq
        print("Aperçu des premières lignes :")
        print(df_title_basics.head())
        print("Aperçu des dernières lignes :")
        print(df_title_basics.tail())
        print("Aperçu de lignes au hasard :")
        print(df_title_basics.sample(5))
```

```
RangeIndex: 11248099 entries, 0 to 11248098
Data columns (total 9 columns):
  Column
                   Dtype
--- -----
                    object
0
    tconst
    titleType
1
                    object
    primaryTitle
                    object
  originalTitle
                    object
3
4
   isAdult
                    object
5
    startYear
                    object
    endYear
6
                    object
7
    runtimeMinutes object
8
    genres
                    object
dtypes: object(9)
memory usage: 772.3+ MB
None
          tconst titleType primaryTitle originalTitle isAdult startYear \
                                              11248080 11248099 11248099
count
        11248099
                   11248099
                                11248080
unique
        11248099
                         11
                                 5048924
                                               5073560
                                                             44
                                                                      152
top
       tt0000001 tvEpisode Episode #1.1 Episode #1.1
                                                              0
                                                                       \N
freq
               1
                    8640119
                                   53438
                                                53438 10822407
                                                                  1417048
        endYear runtimeMinutes
                                 genres
count
       11248099 11247466
                           944
                                   2384
unique
             98
top
             \N
                           \N
                                  Drama
freq
       11115881
                       7700622
                                1275001
Aperçu des premières lignes :
     tconst titleType
                                primaryTitle
                                                       originalTitle \
0 tt0000001
                short
                                  Carmencita
                                                          Carmencita
                short Le clown et ses chiens Le clown et ses chiens
1 tt0000002
             short
                                Poor Pierrot
                                                    Pauvre Pierrot
2 tt0000003
3 tt0000004
              short
                                 Un bon bock
                                                         Un bon bock
4 tt0000005
             short
                           Blacksmith Scene
                                                  Blacksmith Scene
  isAdult startYear endYear runtimeMinutes
                                                            genres
0
             1894
       0
                        \ N
                                       1
                                                 Documentary, Short
              1892
                                       5
1
       0
                                                   Animation, Short
                        \N
2
       0
              1892
                        \N
                                       5 Animation, Comedy, Romance
3
       0
              1892
                        \N
                                      12
                                                   Animation, Short
4
       0
              1893
                                       1
                                                      Comedy, Short
                        \N
Aperçu des dernières lignes :
            tconst titleType
                                           primaryTitle \
11248094 tt9916848 tvEpisode
                                          Episode #3.17
11248095 tt9916850 tvEpisode
                                          Episode #3.19
11248096 tt9916852 tvEpisode
                                          Episode #3.20
11248097 tt9916856
                                               The Wind
                        short
11248098 tt9916880 tvEpisode Horrid Henry Knows It All
                     originalTitle isAdult startYear endYear runtimeMinutes \
11248094
                     Episode #3.17
                                        0
                                               2009
                                                         \N
                                                                       \N
11248095
                     Episode #3.19
                                        0
                                               2010
                                                         \N
                                                                       \N
                     Episode #3.20
                                               2010
11248096
                                        0
                                                         \ N
                                                                       \N
11248097
                          The Wind
                                        0
                                               2015
                                                         \N
                                                                       27
11248098 Horrid Henry Knows It All
                                        0
                                               2014
                                                         \N
                                                                       10
                             genres
11248094
                Action, Drama, Family
```

<class 'pandas.core.frame.DataFrame'>

11248095

Action, Drama, Family

```
11248097
                             Short
11248098 Adventure, Animation, Comedy
Aperçu de lignes au hasard :
            tconst titleType \
         tt6183610 tvEpisode
9547590
36993
        tt0037661
                        short
8847691 tt4597008 tvEpisode
5803100 tt22782398 tvEpisode
6624298 tt27732181 tvEpisode
                                            primaryTitle \
9547590
                                           Episode #2.31
36993
                                            Duck Pimples
8847691 Full Figured Teacher-Tie Me Up and Make Me Cum...
5803100
                               La verità e altri impicci
6624298
                                                 Weather
                                           originalTitle isAdult startYear \
9547590
                                           Episode #2.31
                                                             0
                                                                     2016
36993
                                            Duck Pimples
                                                              0
                                                                     1945
                                                            1
8847691 Full Figured Teacher-Tie Me Up and Make Me Cum...
                                                                     2014
                               La verità e altri impicci
                                                                     2012
5803100
6624298
                                                 Weather
                                                                     1981
       endYear runtimeMinutes
                                               genres
                          \N
9547590
            \N
                                            Talk-Show
36993
            \N
                          8 Animation, Comedy, Family
8847691
            \N
                          \N
5803100
            \N
                          \N
                                 Comedy, Drama, Mystery
6624298
                          15
            \N
                                               Family
 Étape 2 : Inspection des Données
```

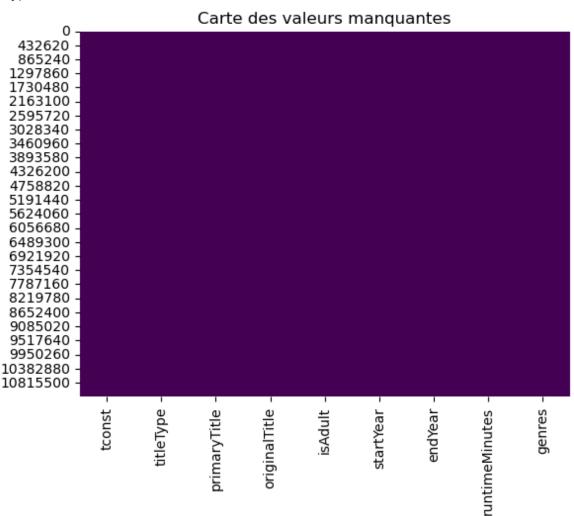
Action, Drama, Family

11248096

```
In [6]: # 1. Vérification des dimensions :
        print(df_title_basics.shape) # Nombre de lignes et de colonnes
       (11248099, 9)
In [7]: # 2. Identifier les valeurs manquantes
        missing_values = df_title_basics.isnull().sum()
        print("Valeurs manquantes par colonne :")
        print(missing_values)
        # Visualisation des valeurs manquantes : NE FONCTIONNE PAS A MODIFIER
        sns.heatmap(df title basics.isnull(), cbar=False, cmap='viridis')
        plt.title("Carte des valeurs manquantes")
        plt.show()
```

```
Valeurs manquantes par colonne :
tconst
titleType
                    0
primaryTitle
                   19
originalTitle
                   19
isAdult
startYear
                    0
endYear
                    0
runtimeMinutes
genres
                  633
dtype: int64
```

0



```
In [8]: # 3. Identification des doublons :
    print(df_title_basics.duplicated().sum()) # Nombre de lignes dupliquées
```

In [9]: # 4. Vérifier les types de données et informations globales

print(df_title_basics.info()) # Types de données, valeurs non nulles
print(df_title_basics.describe(include='all')) # Statistiques générales pour to

```
<class 'pandas.core.frame.DataFrame'>
       RangeIndex: 11248099 entries, 0 to 11248098
       Data columns (total 9 columns):
        # Column
                        Dtype
       ---
                         ----
       0 tconst
                         object
        1 titleType
                         object
        2 primaryTitle
                         object
        3 originalTitle object
        4
          isAdult
                         object
        5 startYear
                         object
        6 endYear
                         object
        7
           runtimeMinutes object
           genres
                         object
        8
       dtypes: object(9)
       memory usage: 772.3+ MB
       None
                tconst titleType primaryTitle originalTitle isAdult startYear \
               11248099 11248099
                                                 11248080 11248099 11248099
       count
                                     11248080
       unique
              11248099
                              11
                                     5048924
                                                 5073560
                                                               44
                                                                        152
              tt0000001 tvEpisode Episode #1.1 Episode #1.1
       top
                                                               0
                                                                        \N
       freq
                     1 8640119 53438 53438 10822407
                                                                    1417048
              endYear runtimeMinutes
                                      genres
              11248099 11247466
       count
                                944
                                        2384
       unique
                   98
                                       Drama
       top
                   \N
                                \N
                                     1275001
       freq
              11115881
                            7700622
In [10]: # regarder combien de lignes ont une donnée abérante dans 'isAdult' ?
        df title basics["isAdult"].unique()
        df_title_basics["isAdult"].value_counts()
```

Out[10]:	isAdult			
	0	10822407	,	
	1	359524		
	0	63526	•	
	1	2009)	
	1985	79)	
	1980	63		
	1978	54		
	1984	41		
	1974	32		
	1982	32		
	1972	29		
	2015	28		
	1983	25		
	2016	21		
	1977	20		
	1976	18		
	1975	18		
	1973	18		
	1981	18		
	1986	17		
	2017	17		
	1987	13		
	1979	13		
	2020	9		
	2018	9		
	2013	8		
	2013	7		
		7		
	2023 2014	6		
	1966	5		
	1988	5		
	2024	4		
	1968	3		
	2022	2		
	1970	2		
	1971	2		
	1969	1		
	1967	1		
	1964	1		
	\N	1		
	2012	1		
	2021	1		
	2011	1		
	2005			
	Name: c	ount, dty	pe:	1NT64

Actions à mener sur les formats de colonnes

#	Column	Dtype	Conclusion
0	tconst	object	> censé être un string, donc ok pour le format
1	titleType	object	> censé être un string, donc ok pour le format. Semble être des catégories, donc nombre limité de chaines de caractères différentes.
2	primaryTitle	object	> censé être un string, donc ok pour le format

```
Column
                             Dtype
                                                           Conclusion
                             object --> censé être un string, donc ok pour le format
           3 originalTitle
           4 isAdult
                             object --> censé être un booléen (0 ou 1), donc MAUVAIS FORMAT
                                     --> censé être une date (datetime), donc MAUVAIS FORMAT --
             startYear
                             object
                                     > NON plutôt INTEGER
                                     --> censé être une date (datetime), donc MAUVAIS FORMAT --
          6 endYear
                             object
                                     > NON plutôt INTEGER
           7 runtimeMinutes object --> censé être un integer, donc MAUVAIS FORMAT
                                    --> contient une chaine caractères (string) qui représente une
                             object succession d'éléments séparés par des virgules. MAUVAIS
           8 genres
                                    FRMAT POUR UN EXPLODE, bon format pour un SPLIT
In [11]: df_title_basics[df_title_basics['tconst']=='tt2457282']
Out[11]:
                      tconst titleType primaryTitle originalTitle isAdult startYear endYear r
                                                      Gekijouban
                                         Puella Magi
                                                          Mahou
                                            Madoka
                                                           shojo
          6091493 tt2457282
                                                                       0
                                                                              2013
                                                                                         \N
                                          Magica the
                                 movie
                                                         Madoka
                                          Movie Part
                                                          magika
                                               III: ...
                                                       Shinpen: ...
In [12]: # 5. Reformatage des colonnes au type (format) incorrect :
          # Étape 1 : Conversion des colonnes numériques avec remplacement des Nan par 0 (
          df_title_basics_copy[['startYear', 'endYear', 'runtimeMinutes']] = df_title_basi
              ['startYear', 'endYear', 'runtimeMinutes']
          ].apply(pd.to_numeric, errors='coerce').fillna(0).astype(int)
          # Étape 2 : Nettoyage de la colonne isAdult
          # Convertir toutes les valeurs de isAdult en numériques, en remplaçant les valeu
          df_title_basics_copy['isAdult'] = pd.to_numeric(df_title_basics_copy['isAdult'],
          # Supprimer les lignes où isAdult contient des années ou des valeurs non valides
          df_title_basics_copy = df_title_basics_copy[df_title_basics_copy['isAdult'].isin
          # Étape 3 : Conversion en booléen
          df_title_basics_copy['isAdult'] = df_title_basics_copy['isAdult'].astype('boolea'
In [13]: # regarder combien de lignes ont une donnée abérante dans 'isAdult' ?
          print("Avant reformatage et nettoyage : ")
          print(df_title_basics["isAdult"].unique())
          print(df_title_basics["isAdult"].value_counts())
          print("Après reformatage et nettoyage : ")
          print(df_title_basics_copy["isAdult"].unique())
          print(df_title_basics_copy["isAdult"].value_counts())
```

Name: count, dtype: int64

Après reformatage et nettoyage :

<BooleanArray>
[False, True]

Length: 2, dtype: boolean

isAdult

\N

False 10885933 True 361533

Name: count, dtype: Int64

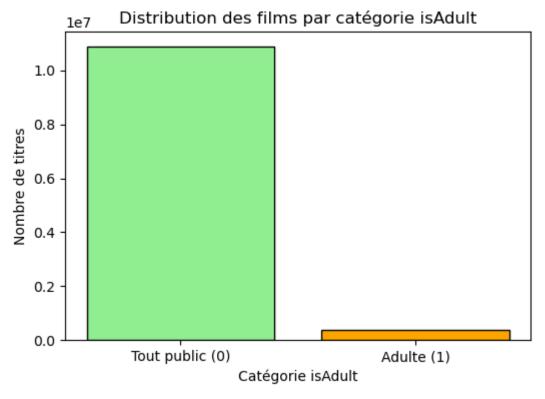
Étape 3 : Analyse des Variables

```
In [14]: # 6. Étudier la distribution des colonnes

# Analyse et visualisation de isAdult
    is_adult_counts = df_title_basics_copy['isAdult'].value_counts()

# Graphique en barres pour isAdult
    plt.figure(figsize=(6, 4))
    plt.bar(is_adult_counts.index, is_adult_counts.values, color=['lightgreen', 'ora
    plt.xticks([0, 1], labels=['Tout public (0)', 'Adulte (1)'])
    plt.xlabel('Catégorie isAdult')
    plt.ylabel('Nombre de titres')
    plt.title('Distribution des films par catégorie isAdult')
    plt.show()

# Afficher Les proportions
    proportions = is_adult_counts / is_adult_counts.sum() * 100
    print("Proportions des catégories isAdult (%):")
    print(proportions)
```



```
Proportions des catégories isAdult (%): isAdult
False 96.785649
True 3.214351
Name: count, dtype: Float64
```

```
In [15]: # 7. Vérifier la présence de doublons (NE MARCHE PAS AVEC LE FORMAT LISTE SUR LE
duplicated_rows = df_title_basics[df_title_basics.duplicated()]
print(f"Nombre de doublons : {len(duplicated_rows)}")
```

Nombre de doublons : 0

```
In [16]: # 8. Explorer les relations entre les colonnes (PAS UTILE SUR CE DATASET, car pa
```

```
# Corrélation entre variables numériques :

# correlation_matrix = df_title_basics_copy.corr()
# sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt='.2f')
# plt.title("Matrice de corrélation")
# plt.show()

# Relations entre variables :

# sns.pairplot(df_title_basics_copy.select_dtypes(include=[np.number]))
# plt.show()
```

```
In [17]: # 9. Étudier les valeurs aberrantes (PAS UTILE SUR CE DATASET, car pas de donnée

# for col in df_title_basics.df_title_basics_copy(include=[np.number]).columns:

# sns.boxplot(x=df_title_basics_copy[col])

# plt.title(f"Boîte à moustaches pour {col}")

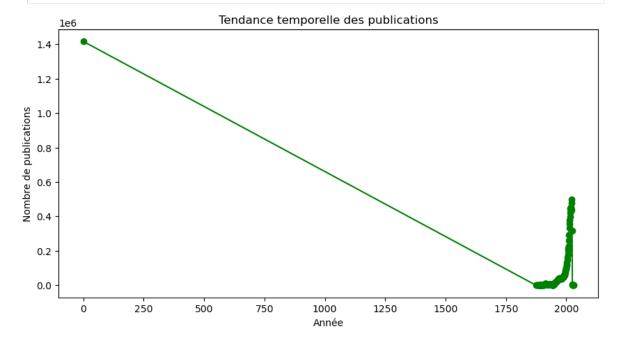
# plt.show()
```

```
In [18]: # 10. Explorer la distribution temporelle

# Analyse des séries temporelles

# Grouper par année et calculer le nombre d'occurrences
yearly_counts = df_title_basics_copy.groupby('startYear').size()

# Visualisation
yearly_counts.plot(kind='line', figsize=(10, 5), marker='o', color='green')
plt.title("Tendance temporelle des publications")
plt.xlabel("Année")
plt.ylabel("Nombre de publications")
plt.show()
```



```
In [19]: # Décennie = année - (année % 10)
    df_title_basics_copy['decade'] = (df_title_basics_copy['startYear'] // 10) * 10

# Compter le nombre de films par décennie
    films_per_decade = df_title_basics_copy.groupby('decade').size().reset_index(nam

# Afficher les résultats
```

```
print(films_per_decade)
 # Visualiser
 plt.figure(figsize=(10, 5))
 plt.bar(films_per_decade['decade'], films_per_decade['film_count'], width=8, col
 plt.xlabel('Décennie')
 plt.ylabel('Nombre de films')
 plt.title('Nombre de films par décennie')
 plt.xticks(films_per_decade['decade'])
 plt.show()
    decade
             film_count
0
                 1416415
1
       1870
                      32
2
       1880
                      79
3
       1890
                    6080
4
       1900
                   25762
5
       1910
                   72552
6
      1920
                   36950
7
       1930
                   32655
8
       1940
                   29349
9
       1950
                  159490
10
       1960
                  311617
11
       1970
                  388484
12
       1980
                  456860
13
       1990
                  737310
14
                 1606215
       2000
15
       2010
                 3794551
16
       2020
                 2173053
17
       2030
                      12
                                  Nombre de films par décennie
     1e6
  3.5
  3.0
Nombre de films
  2.5
  2.0
  1.5
  1.0
  0.5
  0.0
```

Etape 4 : Sélection des données désirées

Décennie

```
# Avoir la liste de toutes les valeurs possibles pour le 'genres'
         liste_genres = ['Action', 'Adult', 'Adventure',
                         'Animation', 'Biography', 'Comedy',
                           'Crime', 'Documentary', 'Drama', 'Family',
                             'Fantasy', 'Game-Show', 'History',
                               'Horror', 'Music', 'Musical', 'Mystery',
                                 'News', 'Reality-TV', 'Romance', 'Sci-Fi',
                                   'Short', 'Sport', 'Talk-Show', 'Thriller',
                                     'War', 'Western', '\\N']
         # Parcourir la liste des genres
         for genre in liste_genres :
            # Créer une nouvelle colonne pour chaque genre
            df_title_basics_copy[genre] = df_title_basics_copy['genres'].str.contains(ge
         # Afficher un échantillon des données
         print(df_title_basics_copy.sample(5))
                    tconst titleType
                                                      primaryTitle \
                                       Episode dated 26 August 2005
       5709237
                 tt2226879 tvEpisode
       325131
                 tt0339549
                               movie
                                                Queen of the Wicked
       2284276 tt12382100 tvEpisode
                                                      Episode #5.68
       7296212 tt30387403 tvEpisode Escapism: Our Brave New World
       3296875 tt14269930 tvEpisode
                                                              2016
                               originalTitle isAdult startYear endYear
                 Episode dated 26 August 2005
       5709237
                                               False
                                                           2005
       325131
                          Oueen of the Wicked
                                                False
                                                           1916
                                                                       0
       2284276
                               Episode #5.68
                                               False
                                                                       0
                                                             0
       7296212 Escapism: Our Brave New World
                                               False
                                                           2017
                                                                       0
       3296875
                                        2016
                                                False
                                                           2021
                                                                       0
                runtimeMinutes
                                                genres decade ...
                                                                    Reality-TV \
       5709237
                                             Game-Show
                            a
                                                         2000
                                                                         False
       325131
                            0
                                               Mystery
                                                          1910
                                                                         False
       2284276
                            22 Comedy,Crime,Reality-TV
                                                           0 ...
                                                                         True
       7296212
                                                 Short
                                                                         False
                            0
                                                          2010
                                                               . . .
       3296875
                             0
                                   Documentary, History
                                                         2020 ...
                                                                         False
                Romance Sci-Fi Short Sport Talk-Show Thriller
                                                                    War Western \
       5709237
                  False False False
                                                 False
                                                           False False
                                                                           False
                         False False False
                                                  False
                                                           False False
                                                                           False
       325131
                  False
                                                 False
       2284276
                  False False False
                                                           False False
                                                                           False
                                                False
       7296212
                  False False True False
                                                           False False
                                                                           False
                  False False False False
       3296875
                                                           False False False
                   \ N
       5709237 False
       325131
                False
       2284276 False
       7296212 False
       3296875 False
       [5 rows x 38 columns]
In [22]: # Vérification du nombre d'élément par valeur :
         liste_genres = ['Action', 'Adult', 'Adventure', 'Animation', 'Biography', 'Comed
         for i in liste genres :
            print (df_title_basics_copy[i].value_counts())
```

Action

False 10422402 True 463531

Name: count, dtype: int64

Adult

False 10885906 True 27

Name: count, dtype: int64

Adventure

False 10460746 True 425187

Name: count, dtype: int64

Animation

False 10327857 True 558076

Name: count, dtype: int64

Biography

False 10765735 True 120198

Name: count, dtype: int64

Comedy

False 8694004 True 2191929

Name: count, dtype: int64

Crime

False 10424129 True 461804

Name: count, dtype: int64

Documentary

False 9819795 True 1066138

Name: count, dtype: int64

Drama

False 7717909 True 3168024

Name: count, dtype: int64

Family

False 10061278 True 824655

Name: count, dtype: int64

Fantasy

False 10652442 True 233491

Name: count, dtype: int64

Game-Show

False 10458217 True 427716

Name: count, dtype: int64

History

False 10719843 True 166090

Name: count, dtype: int64

Horror

False 10682793 True 203140

Name: count, dtype: int64

Music

False 10389325 True 496608

Name: count, dtype: int64

```
Musical
       False 10793528
       True
                  92405
       Name: count, dtype: int64
       Mystery
       False
                10660119
       True
                225814
       Name: count, dtype: int64
       News
       False 9827586
       True
               1058347
       Name: count, dtype: int64
       Reality-TV
       False 10258132
       True
                627801
       Name: count, dtype: int64
       Romance
       False 9843877
               1042056
       Name: count, dtype: int64
       Sci-Fi
       False 10769050
                116883
       True
       Name: count, dtype: int64
       Short
       False 9694563
       True
               1191370
       Name: count, dtype: int64
       Sport
       False 10612145
                 273788
       True
       Name: count, dtype: int64
       Talk-Show
       False 9499330
       True
               1386603
       Name: count, dtype: int64
       Thriller
       False 10700262
       True
                 185671
       Name: count, dtype: int64
       War
       False 10847046
       True
                   38887
       Name: count, dtype: int64
       Western
       False 10855028
                   30905
       True
       Name: count, dtype: int64
         --> il reste 27 films True dans la colonne 'Adult', ils n'avaient pas l'attribut 'IsAdult' = True
         (et donc qui n'avaient pas pu être supprimés)
In [23]: # Suppression des données non désirées dans la colonne 'Adult' (issu de la colon
         df_title_basics_copy = df_title_basics_copy[df_title_basics_copy['Adult'] == Fal
In [24]: # Vérification si on a bien supprimé les Adult restants :
```

df_title_basics_copy['Adult'].value_counts()

```
Out[24]: Adult
         False 10885906
         Name: count, dtype: int64
In [25]: # Combien d'éléments par 'titleType' :
         df_title_basics_copy['titleType'].value_counts()
Out[25]: titleType
                    8400536
         tvEpisode
         short
                       1026210
                       688341
         movie
         tvSeries
                        270117
         video
                        193543
         tvMovie
                        148803
         tvMiniSeries 57591
                         50232
         tvSpecial
         videoGame
                         40065
         tvShort
                          10467
         tvPilot
         Name: count, dtype: int64
In [26]: # Conserver uniquement 'titleType' = movie ou = short
         df_title_basics_copy = df_title_basics_copy[df_title_basics_copy['titleType'] ==
         # Apliquer le get_gummies sur la colonne 'titleType' :
         df_dummies = pd.get_dummies(df_title_basics_copy['titleType'])
         df_title_basics_copy = pd.concat([df_title_basics_copy, df_dummies],
                  axis = 1
In [27]: # Supprimer les colonnes :
         df_title_basics_copy = df_title_basics_copy.drop(['endYear','\\N','isAdult','pri
         # Voir le résultat :
         df_title_basics_copy.sample(10)
```

5323283	tt2101352	movie	2011	90	Documentary,Drama	2010
4352519	tt1632656	movie	2007	61	Documentary	2000
6492749	tt27369477	movie	2023	0	Documentary	2020
107664	tt0110166	movie	1994	55	Documentary	1990
16583	tt0016840	movie	1926	60	Comedy,Drama	1920
438386	tt0456737	movie	1921	0	Drama	1920
5744734	tt2246599	movie	2012	95	Drama,Romance	2010
11165267	tt9737940	movie	2018	48	Drama	2010
7235865	tt3014696	movie	1990	0	Drama	1990
92147	tt0094248	movie	1986	88	Drama	1980

10 rows × 34 columns

```
In [28]: # Combien d'éléments par valeur de 'startYear' :
         df_title_basics_copy['startYear'].value_counts()
Out[28]: startYear
               101266
         2022
                 20442
         2023
                 20021
         2018
                 19179
         2019
                 19075
         2030
         1894
                      1
         1896
                      1
                      1
         2028
         2031
                      1
         Name: count, Length: 138, dtype: int64
In [29]: # Combien d'éléments par valeur de 'runtimeMinutes' :
         display(df_title_basics_copy['runtimeMinutes'].value_counts())
```

```
runtimeMinutes
        255171
90
          28222
80
          12219
60
          12146
          11756
28643
              1
1325
              1
384
570
              1
990
              1
Name: count, Length: 517, dtype: int64
```

	tconst	titleType	startYear	runtimeMinutes	genres	decade
610	tt0000615	movie	1907	0	Drama	1900
625	tt0000630	movie	1908	0	Drama	1900
668	tt0000675	movie	1908	0	Drama	1900
828	tt0000838	movie	1909	0	\N	1900
832	tt0000842	movie	1909	0	\N	1900
•••						
11247776	tt9916178	movie	0	0	\N	0
11247780	tt9916188	movie	0	0	Thriller	0
11247897	tt9916428	movie	2019	0	Adventure, History, War	2010
11247989	tt9916620	movie	0	0	Drama	0
11248029	tt9916706	movie	2013	0	Comedy	2010

262597 rows × 34 columns

	tconst	titleType	startYear	runtimeMinutes	genres	decade
610	tt0000615	movie	1907	0	Drama	1900
625	tt0000630	movie	1908	0	Drama	1900
668	tt0000675	movie	1908	0	Drama	1900
828	tt0000838	movie	1909	0	\N	1900
832	tt0000842	movie	1909	0	\N	1900
•••						
11247776	tt9916178	movie	0	0	\N	0
11247780	tt9916188	movie	0	0	Thriller	0
11247897	tt9916428	movie	2019	0	Adventure, History, War	2010
11247989	tt9916620	movie	0	0	Drama	0
11248029	tt9916706	movie	2013	0	Comedy	2010

```
In [32]: df_title_basics_copy.info()
       <class 'pandas.core.frame.DataFrame'>
       Index: 688341 entries, 8 to 11248049
       Data columns (total 34 columns):
           Column
                         Non-Null Count
                                          Dtype
           -----
                           -----
                           688341 non-null object
        0
          tconst
           titleType
                         688341 non-null object
        1
        2
           startYear
                           688341 non-null int32
        3 runtimeMinutes 688341 non-null int32
        4 genres
                           688341 non-null object
        5 decade
                           688341 non-null int32
        6 Action
                           688341 non-null bool
        7 Adult
                           688341 non-null bool
        8 Adventure
                           688341 non-null bool
        9 Animation
                           688341 non-null bool
        10 Biography
                           688341 non-null bool
        11 Comedy
                           688341 non-null bool
        12 Crime
                           688341 non-null bool
        13 Documentary
                           688341 non-null bool
        14 Drama
                           688341 non-null bool
        15 Family
                           688341 non-null bool
        16 Fantasy
                           688341 non-null bool
        17 Game-Show
                           688341 non-null bool
        18 History
                           688341 non-null bool
        19 Horror
                           688341 non-null bool
                           688341 non-null bool
        20 Music
        21 Musical
                           688341 non-null bool
        22 Mystery
                           688341 non-null bool
        23 News
                           688341 non-null bool
        24 Reality-TV
                           688341 non-null bool
        25 Romance
                           688341 non-null bool
        26 Sci-Fi
                           688341 non-null bool
        27 Short
                           688341 non-null bool
        28 Sport
                           688341 non-null bool
        29 Talk-Show
                           688341 non-null bool
        30 Thriller
                           688341 non-null bool
                           688341 non-null bool
        31 War
        32 Western
                           688341 non-null bool
        33 movie
                           688341 non-null bool
       dtypes: bool(28), int32(3), object(3)
       memory usage: 47.3+ MB
```

```
In [33]: # Exporter en CSV

df_title_basics_copy.to_csv('../gitignore/title_basics_traite.csv', index=False,
```